

RETOS INTELIGENCIA ARTIFICIAL 2026

Búsqueda Semántica

JHON ZHEN YABSE MARIN CUERVO

JHONATAN STEVEN PÉREZ QUIROZ

Unidad 4: Inteligencia Artificial Moderna

Universidad de Boyacá | Facultad de Ingeniería

EL PROBLEMA



Búsqueda Léxica (Tradicional)

Los sistemas actuales fallan al no encontrar coincidencias exactas. Si un usuario busca "crisis", el sistema ignora artículos titulados "recesión", perdiendo información crítica.



Solución Semántica

Implementar un modelo que entienda el **significado profundo**. Transformamos texto en vectores matemáticos donde la cercanía geométrica es cercanía conceptual.

| FASE 1: INGESTA DE DATOS

Corpus de BBC News


Utilizamos el dataset **BBC News Summary**, consolidando miles de archivos de texto en una estructura relacional única.

- ✓ 2,225 Artículos originales.
- ✓ 5 Categorías balanceadas.
- ✓ Semilla Aleatoria (42) para reproducibilidad.



FASE 2: ANÁLISIS EXPLORATORIO

Distribución por Categoría



Hallazgo: El dataset presenta un balanceo óptimo, evitando sesgos significativos hacia una temática específica durante el entrenamiento.

FASE 3: LIMPIEZA DE DATOS



Protocolo de Normalización

Aplicamos RegEx para eliminar ruido y unificar el vocabulario:

```
text = text.lower()
text = re.sub(r'\s+', ' ', text)
text = re.sub(r'^a-z0-9áéíóúñü\.,!?:;()\-£$€% ]', '', text)
```

Filtrado de documentos irrelevantes con menos de 5 palabras para asegurar calidad semántica.

FASE 4: PREPROCESAMIENTO

80/10/10
Estrategia de División

División Estratificada

Garantizamos que cada conjunto mantenga la proporción original de categorías:


- **Train (80%):** Base de conocimiento para generar el corpus vectorial.
- **Validation (10%):** Ajuste de parámetros y análisis de consistencia.
- **Test (10%):** Evaluación ciega de rendimiento final.

FASE 5: MODELADO (TRANSFORMER)

Sentence-Transformers

Implementamos la arquitectura **Bi-Encoder** con el modelo **all-MiniLM-L6-v2**.

- **Dimensiones:** 384 dimensiones densas.
- **Velocidad:** Altamente eficiente para inferencia en CPU/GPU.
- **Métrica:** Similitud de Coseno para el emparejamiento.



VECTORES Y SIMILITUD

Espacio Latente

Cada noticia se convierte en un punto en un espacio de 384 dimensiones. Conceptos similares se agrupan geoméricamente.

Fórmula de Coseno

$$\text{similarity} = \cos(\theta) = \frac{A \cdot B}{\|A\| \|B\|}$$

| FASE 6: MÉTRICAS DE EVALUACIÓN

Consistencia Semántica

Evaluamos si el documento más cercano pertenece a la misma categoría (Top-1 Match).

Precisión Total



Análisis de Errores



Ambigüedad Inter-clase: Noticias de "Tech" que mencionan finanzas de Apple a veces se confunden con "Business". La IA prioriza la semántica tecnológica.

FASE 7: DEMO EN VIVO


Prueba de Inferencia

Input: "financial crisis and bank interest rates"

Top Result [Sim: 0.892]

"The global economy faces new challenges as central banks adjust rates..." (Categoría: Business)

El sistema no buscó la palabra "crisis", buscó el **contexto financiero**.



CONCLUSIONES Y FUTURO

Limitación

Truncamiento a 512 tokens.
Noticias muy largas pierden
información final.

Escalabilidad

Migración a Bases de Datos
Vectoriales (ChromaDB o
Pinecone).

Multilingüe

Implementar modelos para
soporte cross-lingüístico
nativo.

Producción

Despliegue de API vía FastAPI
para integración con CMS
periodísticos.

¿Preguntas?

¡Gracias por su atención!
